《SPoc-Search-based Pseudocode to Code》阅读报告

研究现状

当今自动生成代码的方法只注重句法正确性的度量，而忽视功能上的正确性

研究目标

不同于只使用预测概率最高的生成代码，本文提出一种在搜索空间中寻找可能的能通过测试用例的生成代码。

- 输入：一行行的伪代码（每行包含缩进水平）和公开的测试用例
- 输出：每行对应的真实代码，并让整个程序通过公开和隐藏的测试用例

总流程如图：

```
1   in function main                          int main() {
2     let n be integer                          int n;
3     read n                                    cin >> n;
4     let A be vector of integers               vector<int> A;
5     set size of A = n                         A.resize(n);
6     read n elements into A                    for(int i = 0; i < A.size(); i++) cin >> A[i];
7     for all elements in A                     for(int i = 0; i < A.size(); i++) {
8       set min_i to i                            int min_i = i;
9       for j = i + 1 to size of A exclusive      for(int j = i+1; j < A.size(); j++) {
10        set min_i to j if A[min_i] > A[j]         if(A[min_i] > A[j]) { min_i = j; }
11      swap A[i], A[min_i]                       swap(A[i], A[min_i]);
12    print all elements of A                   for(int i=0; i<A.size(); i++) cout<<A[i]<<" ";
                                              }

    Public test case 1 (out of 5):   5 3 2 4 1 5          →   1 2 3 4 5
    Hidden test case 1 (out of 8):   8 9 2 4 5 6 2 7 1    →   1 2 2 4 5 6 7 9
```

Figure 1: Given L pseudocode lines $x_{1:L}$ (with indentation levels $\ell_{1:L}$) and public test cases, our task is to synthesize a program with code lines $y_{1:L}$. The program is evaluated against both public and hidden test cases.

研究方法

训练集结构如下：

- 伪代码行：x1, x2, x3, ..., xL
- 对应真实代码行：y1, y2, y3, ..., yL
- 公开测试用例：(T1_in, T1_out), (T2_in, T2_out), ..., (Tk_in, Tk_out)
- 隐藏测试用例：(Th1_in, Th1_out), (Th2_in, Th2_out), ..., (Thk_in, Thk_out)

测试集结构如下:

- 伪代码行x
- 公开测试用例

测试时会设置一个最大尝试阈值（computation budget）,每次尝试时会将生成好的程序用公开测试用例测试。超过最大尝试阈值的尝试次数后，若还没找到正确的候选代码行组合，则认为生成代码失败。

主要思想:

1. 输入（xi, yi）对，其中伪代码为xi（一行），yi为对应的真实正确的代码（一行），使用seq2seq+Attention模型，将伪代码xi编码，
2. 使用beam search，设置一个beam size = M，模型将伪代码xi“翻译”为包含M个候选的代码集Ci，每个代码行cij会被模型赋予条件概率p_ij = p(cij | xi)，那么对于L行伪代码x，会形成L个候选代码集C，每个代集中会含有M个候选代码，并将每个候选代码集中的候选代码按其p_ij由大到小排列
3. Best-first search：逐行选择p_ij最高的代码，组装成程序后，使用测试用例进行测试，若期间发生编译错误、运行期错误或测试用例不通过，则用下一个次高p_ij的候选代码替换该行，重新执行测试用例。或直成功通过测试用例或达到最大尝试阈值时停止。

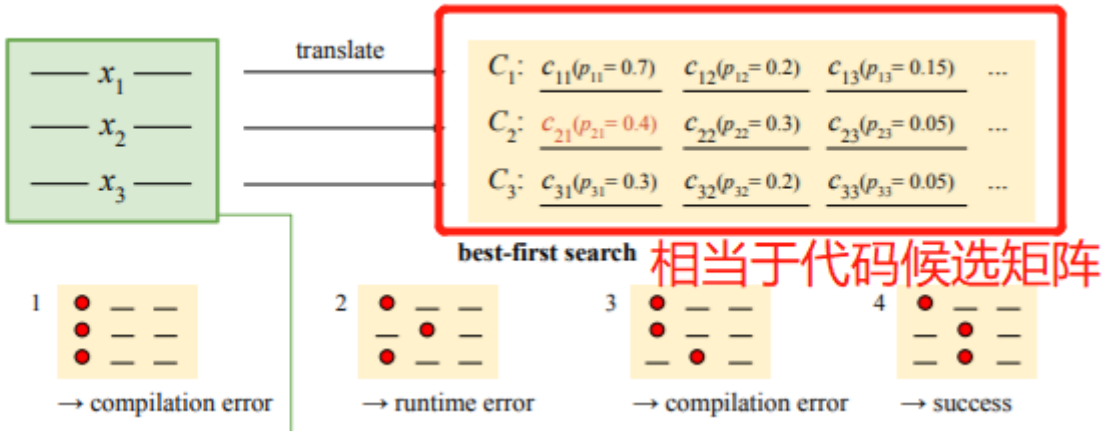

然而，使用best-first search效率很低。本文提出另外一种基于Error localization的搜索后续代码的方法:

当出现编译错误时（作者只考虑编译错误，认为88.7%的代码错误都是编译错误），编译器会告诉出错代码行号i_err和出错信息m_err，但真正有问题的代码行并不一定是编译器告知的那行i_err（譬如某行使用的某变量被告知“xxx变量未声明”，但真正出错那行应该是声明变量那行），然后根据(i_err, m_err)定位出错的真正行号i*，降低此行候选代码参与搜索的权重或直接拉入黑名单（不再搜索）。

具体又分为两种实现方法:

- 多分类方法（Multiclass classification）
  主要用于预测具体出错的代码行i*，如下图所示。

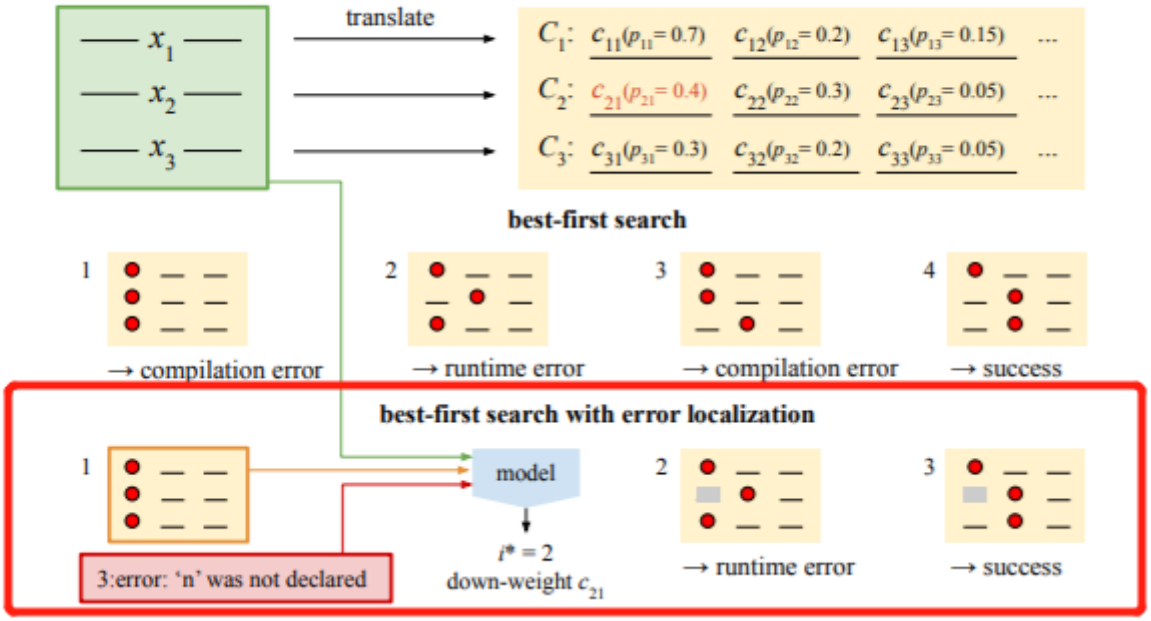

1. 对于每行i，将伪代码xi，和真实代码yi，以及m_err编码，然后分别用三个独立的LSTM训练
2. 将以上每个LSTM最后输出的隐藏状态拼接起来。
3. 计算delta_i = i_err - i，使用位置编码方法（具体参考“Attention is all you need”）将其编码，再将其拼接在2步的向量后面，形成行i的整体嵌入。
4. 将3步的行嵌入输入到另一个LSTM，其输出的隐藏状态再通过一个全连接神经网络进行训练，得到预测的行i*，若预测概率高于95%（超参），则接受i*，否则抛弃
5. 得到i*，将i*行相应的候选代码降权：将其概率p_ij乘以一个小于1的数（超参），以减低其被搜索的概率

- 预剪枝（Prefix-based pruning）
  只尝试编译器告知的出错行的前0、1、2行，找到最小出错的行号，最后将从第1行到此行的候选代码都抛弃掉。（本文认为包含出错行之前的行通常都会使程序不通过）

研究结论

- 对每个程序，每行代码都用概率最高的候选代码组装时，不正确的代码行数占比：

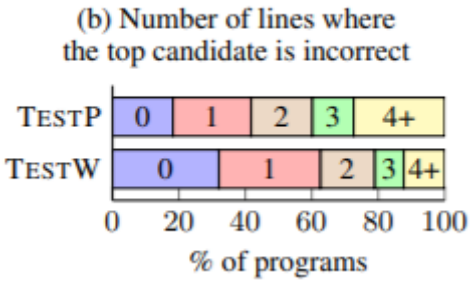

其中测试集TestP为根据程序所属问题的分类来划分的。而测试集TestW是用过人工划分。

可见，在TestP中只有18.2%，而TestW中只有32.0%在使用最高概率候选代码行时，没有一行代码出错。

- 对每个程序，在每个候选集（Ci）里，没有任何正确候选的代码行数占比：

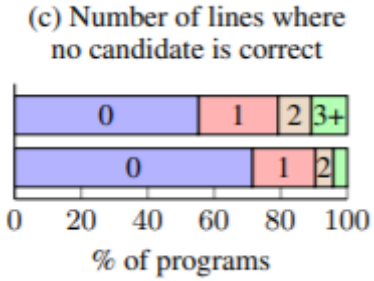

可见，在TestP中至少有1行代码找不到任何候选的占比为44.8%，而在TestW中是28.6%。这说明生成可运行程序的最大成功率，在TestP中为55.2%，在TestP中为71.4%

- 含有Error localization和不含Erro localization的搜索方法对比：

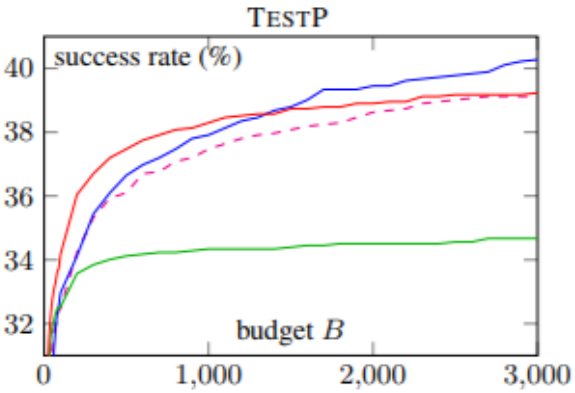

$B =$	10	100	1000	3000
no localization	26.5	32.5	37.5	39.1
$i^* = i_{\text{err}}$	28.0	32.5	34.3	34.7
multiclass	**28.4**	**34.2**	**38.3**	39.2
prefix-based	25.3	33.0	37.9	**40.3**

top-one ($B = 1$): 17.8 oracle ($B = \infty$): 55.2

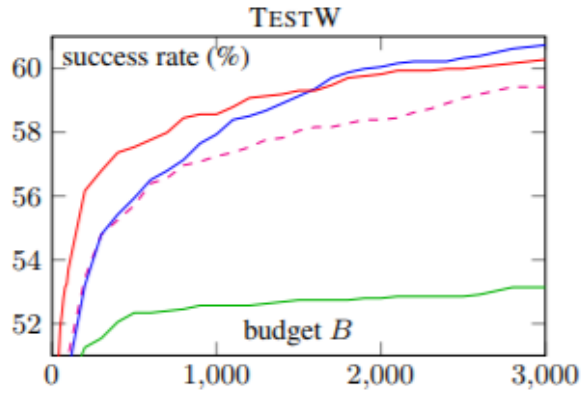

$B =$	10	100	1000	3000
no localization	42.5	51.0	57.3	59.4
$i^* = i_{\text{err}}$	43.5	50.0	52.6	53.1
multiclass	**44.4**	**53.7**	**58.6**	60.3
prefix-based	41.0	50.5	57.9	**60.7**

top-one ($B = 1$): 30.7 oracle ($B = \infty$): 71.4

Figure 4: Success rates at budgets B of best-first search with different error localization methods.

启发

1. 生成代码需要有多个候选，保证程序的完备性（可正确运行）；
2. 需要提供测试用例一起加入训练；
3. 为提高生成候选代码的正确率，应更多的考虑程序的语义，譬如基于AST结构进行编码，而不仅仅像本文所说只是将整行代码按字符流顺序编码

附：

- 文献链接：https://arxiv.org/abs/1906.04908

- 数据集：https://sumith1896.github.io/spoc/